

实验报告

学生姓名:	Tommy	学 号:	20240110
专 业:	Github	年级、班级:	24 级 01 班
课程名称:	模式识别与机器学习	实验项目:	k 近邻算法和决策树
实验类型:	☒ 验证 ☐ 设计 ☐ 综合	实验时间:	2024 年 1 月 10 日
实验指导老师:	Tommy	实验评分:	

1. 实验原理

1.1. k 近邻算法

k 近邻 (k-Nearest Neighbors, kNN) 是一种基本的分类与回归方法。本实验采用 kNN 进行分类, 其基本思想是: 对于一个新的输入实例, 在训练数据集中找到与该实例最邻近的 k 个实例, 这 k 个实例的多数所属的类别即为该输入实例的类别。

距离度量采用欧氏距离 (L_2 距离), 对于两个 n 维样本 $x_i = (x_i^{(1)}, x_i^{(2)}, \dots, x_i^{(n)})^T$ 和 $x_j = (x_j^{(1)}, x_j^{(2)}, \dots, x_j^{(n)})^T$, 其欧氏距离定义为:

$$L_2(x_i, x_j) = \left(\sum_{l=1}^n |x_i^{(l)} - x_j^{(l)}|^2 \right)^{\frac{1}{2}}$$

为了提高泛化能力, 本实验采用 5 折交叉验证选择最优的 k 值, 并扩展实现了曼哈顿距离 (L_1 距离) 作为对比。

1.2. 决策树

决策树是一种基于树结构的分类模型, 每个内部节点表示一个特征上的测试, 每个分支代表一个测试输出, 每个叶节点代表一个类别。本实验实现 ID3 算法和 C4.5 算法。

核心概念包括:

- 信息熵：度量数据集的不确定性。对于数据集 D ，其熵为：

$$H(D) = - \sum_{k=1}^K \frac{|C_k|}{|D|} \log_2 \frac{|C_k|}{|D|}$$

其中 K 为类别数， $|C_k|$ 为第 k 类样本数。

- 条件熵：在已知特征 A 的条件下，数据集 D 的不确定性：

$$H(D|A) = \sum_{i=1}^n \frac{|D_i|}{|D|} H(D_i)$$

- 信息增益：特征 A 带来的不确定性减少量：

$$g(D, A) = H(D) - H(D|A)$$

ID3 算法选择信息增益最大的特征进行划分。

- 信息增益比：为解决 ID3 偏向取值较多特征的问题，C4.5 算法采用信息增益比：

$$g_R(D, A) = \frac{g(D, A)}{H_A(D)}, \quad H_A(D) = - \sum_{i=1}^n \frac{|D_i|}{|D|} \log_2 \frac{|D_i|}{|D|}$$

2. 关键代码

2.1. k 近邻算法

1. 实验 1.1：使用 `print` 功能观察数据

```

1 # 加载鸢尾花数据集
2 iris_data = load_iris() # 从 sklearn 加载鸢尾花数据集
3 X = iris_data.data      # 提取特征矩阵, shape: (150, 4), 4个特征
                           # 分别为花萼长、花萼宽、花瓣长、花瓣宽
4 y = iris_data.target    # 提取标签向量, shape: (150,), 0=Setosa,
                           # 1=Versicolour, 2=Virginica
5
6 # 使用 print 观察数据结构
7 print(f"特征数据 X:\n{X}") # 打印所有特征值, 观察数据范围和分布
8 print(f"标签数据 y:\n{y}") # 打印标签, 观察三类样本的分布情况

```

2. 实验 1.2：调整画图函数的参数

```

1 # 可视化特征 1 (花萼长度) 和特征 2 (花萼宽度)
2 plt.figure(1, figsize=(8, 6)) # 创建画布, 编号为1, 设置图像大小
   为8×6英寸
3 plt.scatter(X[:, 0], X[:, 1], c=y, cmap=plt.cm.Set1, edgecolor="k
   ")
4 # X[:, 0] 取所有样本的第1个特征 (花萼长度)
5 # X[:, 1] 取所有样本的第2个特征 (花萼宽度)
6 # c=y 根据标签值设置不同颜色, 使不同类别的点颜色不同
7 # cmap=plt.cm.Set1 使用 Set1 颜色映射方案
8 # edgecolor="k" 设置散点边缘为黑色, 增强对比度
9
10 plt.xlabel("Sepal length") # 设置 x 轴标签为 "花萼长度"
11 plt.ylabel("Sepal width") # 设置 y 轴标签为 "花萼宽度"
12 fig1_path = ex1_path + "\\figures\\Ex1_Fig1.jpg" # 定义图片保
   存路径
13 plt.savefig(fig1_path) # 将图像保存到指定路径
14 plt.show() # 在屏幕上显示图像
15
16 # 实验 2: 调整画图中的参数 -- colormap, edgecolor, marker 等
17 plt.figure(2, figsize=(8, 6)) # 创建第二个画布, 大小为8×6英寸
18 plt.scatter(X[:, 0], y, cmap=plt.cm.Set2, edgecolor="k")
19 # X[:, 0] 取花萼长度作为 x 轴
20 # y 取标签值作为 y 轴, 可视化特征与类别的关系
21 # cmap=plt.cm.Set2 更换为 Set2 颜色映射
22 # edgecolor="k" 点边缘设为黑色
23
24 plt.xlabel("Sepal length") # x 轴标签
25 plt.ylabel("class") # y 轴标签为 "类别"
26 fig2_path = ex1_path + "\\figures\\Ex1_Fig2.jpg" # 定义图片保
   存路径
27 plt.savefig(fig2_path) # 将图像保存到指定路径
28 plt.show() # 在屏幕上显示图像

```

3. 扩展实验 1.3: 距离更改为曼哈顿距离的代码

```

1 def compute_manhattan_distance(X_test, X_train):
2     """
3     拓展实验 1: 计算测试集与训练集之间的曼哈顿距离
4     参数:
5         X_test: 测试集 (n_test_samples, n_features)
6         X_train: 训练集 (n_train_samples, n_features)
7     返回:
8         距离矩阵 (n_test_samples, n_train_samples)
9     """
10    # 扩展维度以便广播计算, 避免显式循环
11    test_squared = X_test[:, np.newaxis, :] # shape: (n_test,
        1, n_features), 在中间插入新维度
12    train_squared = X_train[np.newaxis, :, :] # shape: (1,

```

```

13         n_train, n_features), 在开头插入新维度
14     # 计算曼哈顿距离:  $L1 = \sum(|x_i - x_j|)$ 
15     distances = np.sum(np.abs(test_squared - train_squared), axis
16                        =2)
17     # np.abs() 计算绝对差值
18     # np.sum(axis=2) 沿特征维度求和, 得到距离矩阵
19     return distances

```

2.2. 决策树

1. 实验 2.1: ID3 算法 (计算条件熵, 信息增益)

```

1 def id3_algo(data, label):
2     """
3     根据信息增益选择最佳划分特征 (ID3 算法)
4     参数:
5         data: 数据集 (DataFrame)
6         label: 标签列名称
7     返回:
8         max_info_gain: 最大信息增益
9         best_feature: 最佳特征名称
10        best_split: 根据最佳特征划分后的子集字典
11    """
12    # Step 1: 计算整个数据集的熵  $H(D)$ 
13    entropy_d = compute_entropy(data[label]) # 调用熵函数, 计
14                                                算原始数据集的不确定性
15
16    # Step 2: 获取所有特征列 (排除标签列)
17    features = [col for col in data.columns if col not in [label
18                                                           ]] # 列表推导式, 提取特征名
19
20    # Step 3: 初始化最优变量
21    max_info_gain = -float("inf") # 初始化为负无穷, 确保任何信
22                                    息增益都能更新
23    best_feature = None # 记录最佳特征名称
24    best_split = None # 记录最佳划分结果
25
26    # Step 4: 遍历每个特征, 计算信息增益
27    for feature in features:
28        # 根据当前特征划分数数据集, 得到不同取值对应的子集
29        splitted_set = split_dataframe(data, feature)
30
31        # Step 4.1: 计算条件熵  $H(D|A) = \sum(|D_i|/|D| * H(D_i))$ 
32        entropy_da = 0 # 初始化条件熵为 0
33        for _, subset in splitted_set.items(): # 遍历每个子集
34            if len(subset) > 0: # 确保子集非空
35                # 计算子集的熵  $H(D_i)$ 
36                entropy_di = compute_entropy(subset[label])

```

```

34         # 加权求和：子集大小占比 × 子集熵
35         entropy_da += len(subset) / len(data) *
            entropy_di
36
37     # Step 4.2: 计算信息增益  $g(D,A) = H(D) - H(D/A)$ 
38     info_gain = entropy_d - entropy_da
39
40     # Step 5: 更新最佳特征（选择信息增益最大的）
41     if info_gain > max_info_gain:
42         max_info_gain = info_gain
43         best_feature = feature
44         best_splited = splited_set
45
46     return max_info_gain, best_feature, best_splited

```

2. 扩展实验 2.2: C4.5 算法

```

1 def c4_5_algo(data, label):
2     """
3     根据信息增益比选择最佳划分特征（C4.5算法）
4     参数：
5         data: 数据集 (DataFrame)
6         label: 标签列名称
7     返回：
8         max_ratio: 最大信息增益比
9         best_feature: 最佳特征名称
10        best_splited: 根据最佳特征划分后的子集字典
11    """
12    # Step 1: 计算整个数据集的熵  $H(D)$ 
13    entropy_d = compute_entropy(data[label])    # 原始数据集的不
        确定性
14
15    # Step 2: 获取所有特征列
16    features = [col for col in data.columns if col != label]
17
18    # Step 3: 初始化最优变量
19    max_ratio = -float("inf")    # 初始化为负无穷
20    best_feature = None          # 记录最佳特征名称
21    best_splited = None          # 记录最佳划分结果
22
23    # Step 4: 遍历每个特征，计算信息增益比
24    for feature in features:
25        splited_set = split_dataframe(data, feature)    # 按特征划
            分数据集
26
27        # Step 4.1: 计算条件熵  $H(D/A)$ 
28        entropy_da = 0    # 初始化条件熵
29        entropy_a = 0    # 初始化特征 A 的熵  $H(A)$ 

```

```

30
31     for _, subset in splited_set.items(): # 遍历每个子集
32         if len(subset) > 0:
33             # 计算子集的熵
34             entropy_di = compute_entropy(subset[label])
35             # 条件熵加权求和
36             entropy_da += len(subset) / len(data) *
37                 entropy_di
38
39             # 计算特征 A 的熵  $H(A) = -\sum(p * \log(p))$ 
40             prob = len(subset) / len(data) # 子集出现的概率
41             if prob > 0: # 避免  $\log(0)$ 
42                 entropy_a += -prob * log(prob, 2) # 累加特
43                 征熵
44
45     # Step 4.2: 计算信息增益
46     info_gain = entropy_d - entropy_da
47
48     # Step 4.3: 计算信息增益比  $g_R = g(D,A) / H(A)$ 
49     if entropy_a > 0: # 避免除零
50         info_gain_ratio = info_gain / entropy_a
51     else:
52         info_gain_ratio = 0 # 特征只有一种取值时，增益比为 0
53
54     # Step 5: 更新最佳特征（选择信息增益比最大的）
55     if info_gain_ratio > max_ratio:
56         max_ratio = info_gain_ratio
57         best_feature = feature
58         best_splited = splited_set
59
60     return max_ratio, best_feature, best_splited

```

3. 实验结果

3.1. k 近邻算法

1. 数据集观察结果

运行 kNN 算法程序后，首先加载并观察鸢尾花数据集。该数据集共包含 150 个样本，每个样本有 4 个特征（花萼长度、花萼宽度、花瓣长度、花瓣宽度），标签分为 Setosa、Versicolour 和 Virginica 三类。按照 7:3 的比例划分为训练集（105 个样本）和测试集（45 个样本）。从可视化结果可以看出，红色类别的样本与灰色、橙色类别分离明显，而灰色与橙色之间存在较大重叠，区

分不明显。




图 1: 可视化特征 1 和特征 2




图 2: 可视化特征 1 和类别 y




图 3: 可视化测试集与训练集实例的距离矩阵（灰度越深表示距离越近）

2. kNN 分类准确率

以 7:3 划分训练集与测试集，采用欧式距离实现 kNN 分类。当 $k = 1$ 时，模型在测试集上准确率约为 73.33%，表明局部近邻可有效判别鸢尾花类别；但过小 k 易受噪声与异常点影响，存在过拟合风险。

3. 5 折交叉验证结果

通过 5 折交叉验证对多组 k 值评估，各折准确率稳定、标准差较小，说明数据集分布均匀、模型泛化能力可靠。交叉验证得到各 k 对应平均准确率，可有效规避单次划分带来的评估偏差，为最优 k 选取提供客观依据。

表 1: 5 折交叉验证不同 k 值的准确率结果

k 值	各折准确率	平均准确率	标准差
1	1.0000, 1.0000, 1.0000, 0.9524, 0.7619	0.9429	0.0923
3	1.0000, 1.0000, 1.0000, 0.9524, 0.7619	0.9429	0.0923
5	1.0000, 1.0000, 1.0000, 1.0000, 0.7619	0.9524	0.0952
8	1.0000, 1.0000, 1.0000, 1.0000, 0.7619	0.9524	0.0952
10	1.0000, 1.0000, 1.0000, 1.0000, 0.7619	0.9524	0.0952
12	1.0000, 1.0000, 1.0000, 1.0000, 0.7619	0.9524	0.0952
15	1.0000, 1.0000, 1.0000, 1.0000, 0.7619	0.9524	0.0952
20	1.0000, 1.0000, 1.0000, 1.0000, 0.7619	0.9524	0.0952
50	1.0000, 1.0000, 1.0000, 1.0000, 0.7143	0.9429	0.1143
100	0.0000, 0.0000, 0.3810, 0.0000, 0.0000	0.0762	0.1524

4. k 值大小的影响

k 值直接控制模型复杂度： k 过小易过拟合，对局部噪声敏感； k 过大会过度平滑，丢失局部特征导致欠拟合。实验中准确率随 k 增大先升后降，当 $k = 5$ 时偏差与方差平衡，分类效果最佳。




图 4: k 值大小的影响

3.2. 决策树

1. 基于信息增益的特征选择

实验以信息增益作为特征划分准则，对学生成绩数据集进行最优特征筛选。结果显示，最大信息增益为 0.3060，最优划分特征为 **Mid-term test**（期中考试成绩）。

依据该特征对数据集进行划分，可将样本分为两类：

- 划分值为 **Low**：包含 2 名学生，期中成绩较低，其中 1 人未通过考试，1 人通过考试，分类不确定性较高；
- 划分值为 **High**：包含 5 名学生，期中成绩较高，全部通过考试，子集纯度较高。

由此可见，期中考试成绩能够有效区分学生是否通过最终考试，具备较强的分类区分能力。

2. 基于信息增益的特征选择

为缓解信息增益对取值较多特征的偏好，实验进一步采用信息增益比作为划分准则。结果显示，最大信息增益比为 0.3545，最优划分特征仍为 **Mid-term test**。

划分结果与信息增益准则完全一致，说明该特征不仅具有较高的信息增益，同时特征取值数量均衡，不会因取值分布产生偏好偏差，稳定性与可靠性更强。

表 2: 决策树特征选择实验结果对比

指标	ID3（信息增益）	C4.5（信息增益比）
最大得分	0.3060	0.3545
最佳划分特征	Mid-term test	Mid-term test
Low 子集标签	Y、N	Y、N
High 子集标签	全部 Y	全部 Y

4. 实验总结

本次实验实现了 k 近邻算法和决策树算法，并在鸢尾花数据集和学生成绩数据集上进行了验证。通过编写代码、调试程序和观察实验结果，我对以下内容有了更深刻的理解：

4.1. k 近邻算法

1. 距离度量的选择：实验对比了欧氏距离和曼哈顿距离，在鸢尾花数据集上两者表现相近，说明对于特征尺度一致且分布良好的数据，距离度量方式的影响较小。
2. k 值的影响：通过 5 折交叉验证发现，当 $k = 1$ 时模型准确率最高，但随着 k 增大，准确率逐渐下降且标准差增大。这表明 k 值过小会导致过拟合（对噪声敏感）， k 值过大会导致欠拟合（过度平滑），选择合适的 k 值对模型性能至关重要。
3. 交叉验证的重要性：5 折交叉验证有效避免了单次训练集划分带来的评估偏差，为最优 k 值的选择提供了客观依据，增强了模型的泛化能力评估。
4. 数据可视化：通过 `matplotlib` 调整散点图的颜色映射、边缘颜色、标记形状等参数，可以更直观地观察数据的分布特征和类别可分性。

4.2. 决策树

1. 信息熵与条件熵：信息熵度量数据集的不确定性，条件熵反映已知特征后的剩余不确定性，两者之差即为信息增益。理解这些概念是掌握决策树算法的关键。
2. ID3 与 C4.5 的差异：ID3 算法使用信息增益作为特征选择准则，容易偏向取值较多的特征；C4.5 算法采用信息增益比进行修正，使特征选择更加公平

合理。实验中两者均选择了 **Mid-term test** 作为最佳特征，说明该特征确实具有较强的分类能力。

3. 决策树的划分过程：通过计算各特征的信息增益（比），选择最优特征进行数据集划分，使得子集纯度不断提高，最终构建出能够正确分类的决策树。

[1]

References

- [1] 作者, 书名. 出版社, 2024.

电子科学与工程学院（微电子学院）

<

《实验记录

學生姓名: _____

学 号: _____

专 业: _____

年级、班级：_____

课程名称: _____

实验项目: _____

实验时间：_____年 月 日

实验准备:

原始记录:

实验指导老师（签名）：_____